Machine Learning Engineering

Diego Valenzuela 22309

Nelson García Bravatti 22434

Sergio Orellana 221122

Joaquín Puente 22296

Daniel Dubón 22233

Ricardo Chuy 221007

Rodrigo Mansilla 22611

Entendimiento del Negocio

1. Contexto y Motivación del Proyecto

El precio del combustible es una variable macroeconómica que fluctúa constantemente, impactando de manera directa el presupuesto individual. Para quienes realizan recorridos diarios en la ciudad o viajes constantes, el gasto en gasolina representa un porcentaje significativo de sus costos operativos.

A pesar de la necesidad de llevar un control financiero el registro manual de cada visita a la gasolinera es una tarea tediosa, propensa a errores y al olvido. Como resultado, la mayoría de los consumidores pierde visibilidad sobre métricas clave tales como las variaciones de precios entre distintas zonas geográficas, fluctuaciones históricas y el volumen real de consumo.

2. Situación Actual y Definición del Problema

Situación Actual

El mercado internacional de hidrocarburos se ve afectado por la volatilidad derivada de tensiones geopolíticas y alteraciones en rutas de transporte marítimo, lo cual tiene una consecuencia directa en Guatemala, al ser el país un importador neto. La cadena de importación se maneja a través de la llegada del producto en buque hasta su distribución. Lo que se traduce a que el precio que se observa en la bomba al momento de echar gas, refleja compras hechas días o semanas antes.

Contexto Específico

El precio en cada bomba se descompone en cuatro componentes

- Costo internacional del producto refinado
- Tipo de cambio
- Carga Tributaria
- Margen de Comercialización de la importadora y la estación

De estos 4, 3 son estandarizados e independientes de quien distribuye la gasolina. El cuarto es donde varía a nivel de estación, en donde cada marca administra el precio de diferente manera.

El Ministerio de Energía y Minas publica los precios de referencia de combustible los martes y se reflejan en estaciones de servicio ese mismo día desde temprano, este precio varía por cabecera departamental y por municipio. Junto a esto, se publica un reporte con las estaciones con los precios más bajos, junto a su número de licencia, marca ,nombre de estación, dirección, municipio y precio por galón.

A partir del contexto, se tienen características que definen el problema.

- El precio no se mueve de manera continua, se mueve los martes.
- Se publican promedios por departamento y un ranking de estaciones más baratas.
- Se publican tres grados, Super, Regular y Diésel.

Políticas Fiscales

Durante 2026 el precio ha estado sujeto a intervenciones fiscales.

Régimen	Vigencia	Diésel	Regular	Superior
R1 — Decreto 11-2026	1 may – 2 jul 2026	Q8.00	Q5.00	Q5.00
R2 — sin subsidio	2 jul 2026 – presente	—	—	—
R3 — Iniciativa 6801	pendiente de aprobación	Q12.00	Q3.00	excluida

Pánorama del Consumidor

Un conductor , toma un rango de decisiones al momento de echar gasolina, a día de hoy las toma sin información.

Decisión		Cómo se resuelve hoy	Costo
Cuándo	hoy , mañana u otro día	Cuando se enciende la luz de reserva	Q0.50–1.00/gal × galones comprados en el momento equivocado
Dónde	cuál estación	La de siempre, o la que queda de camino	Dispersión observada entre estaciones, orden de Q0.50–1.00/gal
Cuánto	monto fijo o llenar	Costumbre o disponibilidad de efectivo	Interactúa con las otras dos; determina si el desvío se paga

La prima de modalidad es el sobrecosto menos visible del mercado. En el monitoreo del MEM del 22 de julio de 2026, la súper promediaba Q41.07 en autoservicio y Q42.10 en servicio completo Q1.03 por galón, mayor que casi cualquier diferencia entre estaciones, y la mayoría de conductores nunca la elige conscientemente.

3.Objetivos del Negocio

Reducir el gasto anual en combustible del conductor urbano guatemalteco, mediante una recomendación integrada de cuándo, dónde y cuánto tanquear. El objetivo no es "encontrar la gasolinera más barata" , es el costo total de mantener el vehículo con combustible, que integra las tres decisiones de la tabla del panorama del consumidor.

Jobs To Be Done

Ejecutor: conductor de hogar del área metropolitana, con vehículo particular y patrón de tanqueo recurrente.

Job: minimizar el costo total de mantener el vehículo con combustible, sin incurrir en costos de búsqueda desproporcionados

#	Outcome	Decisión que ataca
O1	Minimizar el tiempo para determinar si conviene tanquear hoy o esperar al cambio del martes	Cuándo
O2	Minimizar la probabilidad de llenar el tanque en las 48 horas previas a una baja de referencia	Cuándo

O3	Minimizar el sobrecosto por desvío hacia una estación cuyo ahorro no compensa el combustible de llegar, dado el monto que se piensa comprar	Dónde × Cuánto
O4	Minimizar el tiempo para detectar que la estación habitual ya trasladó el cambio de referencia	Dónde
O5	Minimizar la probabilidad de pagar la prima de servicio completo sin haberlo decidido	Modalidad

Objetivos de Machine Learning

Para habilitar los objetivos del negocio, el sistema requiere un pipeline de extracción de información basado en Visión Computacional y extracción de metadatos. El objetivo técnico es implementar un sistema de Reconocimiento Óptico de Caracteres (OCR) capaz de interpretar los dígitos de pantallas de 7 segmentos en los surtidores, cruzando esta información con los metadatos EXIF (fecha, hora y coordenadas GPS) de la fotografía.

5. Criterios de Éxito del Proyecto

- Criterio de Éxito Técnico: El pipeline debe ser capaz de procesar lotes de imágenes y extraer las métricas clave con un alto nivel de confianza. Dada la variabilidad de hardware y sistemas operativos (diferencias de rendimiento entre el framework Vision y Tesseract), el sistema debe ser lo suficientemente robusto para identificar lecturas de baja confianza e implementar un mecanismo de contingencia ("Human-in-the-loop").

- Criterio de Éxito de Negocio: El despliegue exitoso de un dashboard interactivo (Streamlit) que muestre la bitácora actualizada. El sistema no debe comprometer la integridad de la base de datos; por lo tanto, cualquier valor no confirmado automáticamente por el modelo de ML deberá ser enviado a una cola de revisión manual para su validación final, garantizando que el usuario visualice información 100% precisa.

Data Understanding:

La fase de entendimiento de los datos se centra en conocer la naturaleza de la información disponible antes de aplicar procesos de extracción, limpieza o modelado. En este proyecto, la fuente principal de datos son fotografías tomadas con teléfonos iPhone a surtidores de gasolina en distintas estaciones de servicio. Estas imágenes contienen información visual relevante sobre la compra realizada y sobre los precios vigentes de los distintos tipos de combustible.

Cada fotografía funciona como una unidad de observación. Es decir, cada imagen representa una visita o registro potencial de carga de combustible. A partir de ella se busca extraer información como el monto total pagado, la cantidad de galones cargados, el precio por galón y los precios visibles de los distintos combustibles disponibles en la bomba.

1. Fuente de los datos

Los datos provienen de imágenes capturadas manualmente por usuarios al momento de cargar combustible. Las fotografías son tomadas directamente a la bomba de gasolina, por lo que contienen tanto información numérica como elementos visuales propios del surtidor.

En general, las imágenes presentan una estructura similar. Se observa una pantalla principal donde aparece el total de la venta y la cantidad de galones servidos. Además, en la parte inferior de la bomba suelen aparecer los precios por galón de los distintos tipos de combustible, como Diésel, Regular, Súper y, en algunos casos, V-Power u otra variante premium.



Figura 1: Foto del dataset

En la imagen de referencia (Figura 1) se observan los siguientes elementos principales:

Total pagado en la venta: Q150.00

Galones cargados: 3.564

Precio de Diésel: Q43.19 por galón

Precio de Regular: Q41.09 por galón

Precio de Súper: Q42.09 por galón

Precio de V-Power: Q42.09 por galón

Estos datos muestran que una sola fotografía puede aportar información de consumo individual y también información contextual del mercado de precios en esa estación.

2. Tipo de datos disponibles

El conjunto de datos combina información no estructurada y estructurada.

Por un lado, las fotografías son datos no estructurados, ya que la información importante está contenida dentro de una imagen y no en una tabla directamente legible. Para poder utilizarla en un análisis o modelo, es necesario aplicar técnicas de visión computacional y reconocimiento óptico de caracteres.

Por otro lado, las imágenes también pueden contener metadatos estructurados. Al ser tomadas con teléfonos iPhone, las fotografías pueden incluir información EXIF, como fecha, hora y coordenadas GPS, siempre que el dispositivo tenga activada la ubicación al momento de tomar la foto. Esta información es importante porque permite relacionar cada carga de combustible con un momento y una ubicación aproximada.

Fuente dentro del archivo	Tipo de dato	Información esperada
Imagen del surtidor	No estructurado	Total pagado, galones cargados, precios por tipo de combustible
Metadatos EXIF	Estructurado	Fecha, hora, latitud, longitud
Nombre o ruta del archivo	Semiestructurado	Identificador de la imagen, lote de procesamiento, posible usuario o carpeta de origen

3. Variables esperadas

A partir del procesamiento de las fotografías se espera construir una tabla donde cada fila represente una imagen procesada. Las variables principales podrían organizarse de la siguiente manera:

Variable	Descripción	Tipo de dato esperado
image_id	Identificador único de la fotografía	Texto
fecha_hora	Fecha y hora de captura de la imagen	Fecha y hora
latitud	Coordenada GPS de la fotografía	Numérico
longitud	Coordenada GPS de la fotografía	Numérico
total_venta	Monto total pagado en la carga	Numérico
galones	Cantidad de galones cargados	Numérico
precio_calculado	Precio por galón calculado como total dividido entre galones	Numérico
precio_diesel	Precio visible del diésel en la bomba	Numérico
precio_regular	Precio visible de gasolina regular	Numérico
precio_super	Precio visible de gasolina súper	Numérico
precio_premium	Precio visible de gasolina premium, si aplica	Numérico

marca_estacion	Marca visible de la gasolinera, si puede identificarse	Texto
texto_ocr_crudo	Texto detectado originalmente por OCR	Texto
confianza_ocr	Nivel de confianza de la lectura automática	Numérico
estado_validacion	Indica si el registro fue aceptado, corregido o enviado a revisión	Categórico

No todas las variables estarán disponibles en todas las imágenes. Por ejemplo, algunas fotografías pueden no tener metadatos GPS, pueden estar borrosas o pueden no mostrar todos los precios de combustible. Por eso, desde esta fase se reconoce que el dataset tendrá distintos niveles de completitud.

4. Estructura visual de las imágenes

Las fotografías tienen una estructura visual relativamente constante, lo cual favorece el uso de un pipeline automatizado. Usualmente, la pantalla principal del surtidor se encuentra en la parte superior de la imagen y muestra dos valores importantes: el total de la venta y la cantidad de galones. Debajo de esta pantalla aparecen botones o etiquetas correspondientes a los tipos de combustible, cada uno acompañado de su precio por galón.

Sin embargo, aunque la estructura general se mantiene, pueden existir variaciones importantes entre imágenes. Estas variaciones pueden deberse al ángulo desde el cual se toma la fotografía, la distancia hacia la bomba, la iluminación, reflejos sobre la pantalla, sombras, resolución de la imagen o diferencias entre modelos de surtidores. Además, las pantallas de 7 segmentos pueden ser difíciles de leer para un OCR general, ya que los números no siempre tienen la forma típica de una fuente digital convencional.

Por esta razón, el entendimiento visual de los datos es clave. No basta con asumir que cada imagen contiene texto limpio y fácilmente extraíble. El sistema debe considerar que algunos dígitos pueden confundirse, como 8 con 0, 5 con 6, 1 con 7, o que el punto decimal puede no detectarse correctamente.

5. Calidad inicial de los datos

La calidad de los datos depende directamente de la calidad de las fotografías y de la disponibilidad de metadatos. Algunos factores que pueden afectar el procesamiento son:

- Imágenes borrosas por movimiento de la cámara.
- Reflejos de luz sobre la pantalla del surtidor.
- Ángulos inclinados que deforman los números.
- Recortes incompletos donde no se vea toda la bomba.
- Pantallas muy iluminadas o con bajo contraste.
- Falta de coordenadas GPS en los metadatos.
- Diferencias entre marcas o modelos de bomba.
- Presencia de varios precios visibles en una misma imagen.

6. Relevancia de los metadatos EXIF

Los metadatos EXIF son una parte importante del dataset porque permiten enriquecer la información visual con contexto temporal y geográfico. La fecha y hora permiten construir series históricas de consumo, analizar cambios semanales y relacionar los registros con los días en que suelen actualizarse los precios de referencia.

Las coordenadas GPS, cuando están disponibles, permiten ubicar aproximadamente la estación donde se realizó la carga. Esto abre la posibilidad de realizar análisis geoespaciales, comparar zonas de la ciudad, identificar estaciones recurrentes y contrastar precios entre ubicaciones. Sin embargo, esta información debe tratarse con cuidado, ya que puede no estar presente en todas las imágenes o puede requerir una transformación posterior para asociarla con una dirección, municipio o estación específica.

7. Granularidad del dataset

La granularidad inicial del dataset es por fotografía. Cada imagen representa un evento individual de carga o una observación de precios en una estación. A partir de esta unidad se pueden construir niveles de análisis más amplios.

Por ejemplo, a nivel de usuario se puede analizar el historial de consumo, frecuencia de recargas y gasto acumulado. A nivel geográfico se pueden comparar precios por zona o municipio. A nivel temporal se pueden analizar cambios por semana, mes o régimen fiscal. A nivel de estación se puede observar si ciertos puntos mantienen precios más bajos o más altos respecto a otros.

Esta granularidad permite que el mismo dataset sirva tanto para control personal de gastos como para análisis de precios de combustible.

8. Limitaciones identificadas en los datos

Una limitación importante es que la fotografía no siempre confirma explícitamente cuál tipo de combustible fue cargado. En algunos casos se puede inferir comparando el total pagado y los galones con los precios visibles, pero esta inferencia puede ser ambigua si dos

combustibles tienen el mismo precio, como ocurre en la imagen de ejemplo con Súper y V-Power. En esos casos, el registro debe marcarse como indeterminado o requerir validación manual.

Otra limitación es que el OCR puede leer correctamente el total y los galones, pero fallar al detectar los precios inferiores, especialmente si estos aparecen pequeños, inclinados o parcialmente reflejados. También puede ocurrir lo contrario: que los precios sean claros pero la pantalla principal tenga reflejo o sobreexposición.

Finalmente, aunque los datos GPS son útiles, no siempre garantizan una identificación exacta de la estación. La precisión puede variar dependiendo del teléfono, la señal disponible y la configuración de privacidad del usuario.

Data Preparation:

Esta fase cubre todo el camino que recorre la información desde que se toma la foto del dispensador de gasolina hasta que queda lista para alimentar un algoritmo de machine learning. Para ordenar ese camino usamos una arquitectura de tipo medallion, dividida en tres capas: bronze, silver y gold. No es un requisito de CRISP DM, pero encaja de forma natural dentro de la fase de preparación de datos porque cada capa representa un nivel distinto de limpieza y confianza sobre la misma información.

Capa Bronze: datos crudos

En esta primera capa se toman las fotos originales, guardadas en una carpeta compartida (por ejemplo un Drive), y se extrae de ellas toda la información posible sin todavía filtrar ni corregir nada. El proceso incluye:

- Convertir las fotos a un formato de imagen más manejable.
- Leer los metadatos que trae cada foto: fecha y hora en que se tomó, coordenadas GPS de la ubicación.
- Aplicar reconocimiento óptico de caracteres sobre la pantalla del surtidor para leer el total pagado y los galones cargados.

El resultado de esta etapa es un primer archivo, en formato CSV y JSON, que junta por cada foto tanto los valores leídos como el texto crudo que devolvió el lector óptico. Esta capa es intencionalmente cruda: puede tener lecturas incompletas o equivocadas, pero deja un registro completo y trazable de cada foto procesada, lo cual sirve como respaldo si más adelante hay que revisar o reprocesar algo.

Capa Silver: limpieza y validación

A partir del archivo de la capa bronze se hace un proceso de limpieza pensado para dejar cada fila del set de datos en un estado confiable. Las reglas que se aplican son:

- Manejo de valores faltantes: cuando el lector óptico no logra reconocer un valor con suficiente certeza, la fila queda marcada como pendiente de revisión en lugar de inventar un número.
- Corrección manual: existe un mecanismo para que una persona confirme o corrija ese valor a mano cuando quede pendiente.
- Detección de valores atípicos: se compara el precio por galón de cada carga contra la mediana del resto de los datos, y se revisa si el total cobrado se aleja del valor esperado para ese tipo de carga.

Cada fila queda entonces acompañada de indicadores que explican si pasó las validaciones o por qué quedó marcada para revisión, en vez de simplemente borrar los datos dudosos. El resultado de esta capa es un set de datos limpio, donde cada valor está confirmado ya sea de forma automática o por una revisión manual.

Capa Gold: datos listos para el modelo

Esta capa todavía está por definirse a detalle porque depende del algoritmo de machine learning que finalmente se elija, pero la idea general es partir del set de datos ya limpio en silver y dejarlo en una forma pensada específicamente para entrenar un modelo. Esto probablemente incluya:

- Quedarse solo con las filas ya confirmadas, dejando fuera lo que sigue pendiente de revisión.
- Calcular variables derivadas que puedan ser útiles para el análisis, como el día de la semana, el mes, o el tiempo transcurrido entre una carga y otra.
- Aprovechar la información de ubicación ya resuelta en la etapa anterior para, por ejemplo, agrupar los datos por estación de servicio o por zona.

La capa gold sería entonces una tabla más compacta y enfocada en el modelo, separada del set de datos completo que se conserva en silver como historial y auditoría.

Consideraciones sobre el entorno de ejecución

Como el servidor donde va a correr este proceso no es muy potente, el diseño busca ser liviano y evitar trabajo innecesario:

- Procesamiento incremental: cada vez que se agregan fotos nuevas a la carpeta de origen, solo esas fotos se procesan, sin repetir el trabajo ya hecho sobre las anteriores.
- Empaquetado en contenedor: todo el pipeline, junto con las herramientas externas que necesita para leer metadatos e imágenes, se empaqueta en un contenedor de Docker, de modo que se pueda instalar y correr en el servidor sin depender de configuraciones manuales adicionales.
- Interacción inicial: ese mismo contenedor sirve además un dashboard simple donde se pueden revisar las fotos marcadas para confirmación manual, lo cual funciona por

ahora como primera forma de interacción con el pipeline mientras se define un diseño más definitivo para esa parte.